

Recuperação Semântica de Eventos Históricos para Previsão Híbrida de Séries Temporais Financeiras

Jefferson dos Anjos
CEFET/RJ

jefferson.anjos@cefet-rj.br

Luiz Nogaroli

Fernando Queiroz

Felipe da Rocha Henriques
CEFET/RJ

felipe.henriques@cefet-rj.br

Diego Carvalho
CEFET/RJ

dcarvalho@ieee.org

Eduardo Ogasawara
CEFET/RJ

eogasawara@ieee.org

Abstract—This paper proposes a hybrid method for short-horizon financial forecasting that combines quantitative models with semantic retrieval of comparable historical events. The pipeline detects events through return thresholds, structures news into JSON records, associates each event with its realized post-event sequence, and reuses this event library under walk-forward evaluation. The method retrieves semantically similar past events, applies a similarity-weighted impact adjustment, and learns an event-aware residual correction. Experiments on PETR4, PRIO3 and EXXO34, synchronized with Brent, generate 12,159 out-of-sample forecasts across LSTM, recurrent autoencoder and Transformer baselines. In the current configuration, which includes a conservative reranking stage only as a tie-breaker inside a short semantic pool, the hybrid method reduces average RMSE from 1.6248 to 0.8537 (47.5%), reduces average MAE from 1.2445 to 0.6253 (49.8%), and outperforms the base models on 76.2% of the evaluated days. These results show that retrieving comparable historical events is a useful and auditable complement to purely quantitative forecasting.

Index Terms—Financial time series forecasting, event retrieval, news-aware forecasting, hybrid models, semantic similarity, residual correction.

I. INTRODUÇÃO

Mercados financeiros reagem continuamente a informações corporativas, macroeconômicas e geopolíticas. Embora essa premissa seja bem aceita, a incorporação operacional de notícias em modelos preditivos ainda permanece incompleta. Em boa parte da literatura, os modelos são treinados apenas com histórico de preços. Quando o texto é incorporado, seu uso costuma ocorrer como uma variável contemporânea de sentimento ou como um canal adicional de classificação de movimento [1, 2, 3, 4]. Esse desenho deixa em aberto uma questão metodológica importante: como reutilizar eventos históricos semanticamente semelhantes e suas trajetórias observadas de impacto para melhorar previsões numéricas de curto prazo?

O problema é particularmente relevante em ativos expostos a choques recorrentes de commodity, regulação e geopolítica, como os do setor de óleo e gás. Nesses casos, o mesmo tipo de notícia tende a reaparecer em contextos diferentes, com efeitos que nem sempre se esgotam no dia do evento e podem se propagar pelos pregões subsequentes. A abordagem proposta investiga essa lacuna ao converter notícias em eventos estruturados, estimar suas sequências realizadas de impacto e

reaproveitar essas sequências quando um evento semanticamente comparável volta a ocorrer.

A abordagem proposta organiza a camada informacional de forma modular. A avaliação offline principal recupera diretamente pares *motivo-sequência* da biblioteca histórica de eventos, aplica um ajuste por impacto semântico com corte temporal estrito e depois aprende uma correção residual em regime *walk-forward*. Os clusters semânticos continuam existindo, mas cumprem papel principalmente exploratório e de auditabilidade.

Nossa hipótese de pesquisa é que recuperar eventos semanticamente comparáveis e suas sequências observadas de impacto reduz o erro dos modelos base e melhora a auditabilidade da previsão em relação a abordagens puramente quantitativas.

Com base nisso, as contribuições centrais do artigo são:

- uma biblioteca auditável de eventos financeiros estruturados a partir de notícias, com contexto textual, motivos associados e propagação observada de impacto após o evento;
- um mecanismo de recuperação semântica de eventos históricos comparáveis com restrição temporal explícita;
- um modelo híbrido em duas etapas, composto por ajuste sequencial por similaridade e por correção residual *walk-forward*;
- uma avaliação comparativa sobre três arquiteturas de base e três ativos do setor de óleo e gás, com evidências quantitativas, ablações e logs de decisão.

II. REFERENCIAL TEÓRICO

A. Previsão financeira com modelos quantitativos

Modelos baseados em aprendizado profundo têm sido usados com frequência na previsão financeira por sua capacidade de capturar relações não lineares e dependências temporais complexas. Redes LSTM mostraram desempenho competitivo em relação a abordagens tradicionais [5], enquanto Autoencoders recorrentes ajudam a construir representações latentes mais robustas a ruído [6]. Mais recentemente, arquiteturas baseadas em atenção, como o Transformer e suas adaptações para séries temporais, passaram a disputar esse mesmo espaço por sua eficiência em sequências longas e em cenários multi-horizonte [7, 8, 9].

B. Notícias, texto e eventos no mercado financeiro

Há ampla evidência de que texto financeiro e fluxo de notícias afetam retorno, volume e percepção de risco [1, 2, 10, 11]. O desenvolvimento de embeddings distribuídos e de modelos contextualizados ampliou a capacidade de representar semelhança semântica entre frases e eventos [12, 13, 14, 15]. Ainda assim, grande parte dos trabalhos usa o texto como um sinal agregado no instante corrente, e não como um mecanismo explícito de recuperação de padrões históricos de impacto.

C. Reação gradual e memória de eventos

Embora a Hipótese dos Mercados Eficientes proponha incorporação rápida da informação aos preços [16], a literatura também documenta reações graduais, exageros e reversões [17, 18, 19]. Essa linha teórica abre espaço para metodologias que representem o impacto de um evento como uma sequência temporal observável, e não apenas como um choque instantâneo. É precisamente nesse ponto que a recuperação semântica de eventos históricos se torna relevante: ela oferece uma forma concreta de consultar experiências anteriores comparáveis e reutilizar suas trajetórias observadas.

III. TRABALHOS RELACIONADOS

Os trabalhos mais próximos desta proposta podem ser agrupados em quatro famílias. A primeira reúne modelos puramente quantitativos baseados em séries de mercado, como LSTM, Autoencoders e Transformers adaptados para previsão temporal [5, 6, 8]. Essas abordagens servem como base de comparação natural, mas tratam choques informacionais apenas como parte da dinâmica endógena da série.

A segunda família usa notícias, eventos ou textos de redes sociais para prever direção de mercado [20, 21, 3, 4]. O ganho principal desses trabalhos está em incorporar texto ao processo preditivo, mas, em geral, o problema é formulado como classificação de movimento e o texto é fundido ao modelo ponta a ponta, sem gerar uma biblioteca auditável de sequências históricas reutilizáveis.

Além da literatura acadêmica, há implementações públicas amplamente divulgadas que combinam aprendizado profundo, múltiplas fontes de atributos e sinais textuais para previsão de mercado. Um exemplo é o repositório *stockpredictionai*, de Banushev [22], que organiza uma proposta aplicada com GANs, LSTMs, CNNs e diferentes grupos de *features*. Essa linha é relevante como referência prática, mas difere da proposta aqui apresentada por tratar o texto predominantemente como entrada do modelo preditivo, e não como uma biblioteca explícita de eventos históricos com sequências observadas e recuperação auditável.

A terceira família avança para arquiteturas com memória e interações mais estruturadas entre texto, tempo e múltiplos ativos [23]. Já a quarta família aproxima-se de esquemas de recuperação e memória baseados em LLMs ou em recuperação aumentada para previsão [24, 25, 26]. Em ambos os casos, a literatura recente oferece mecanismos sofisticados de memória, mas tende a depender de arquiteturas mais pesadas, foco em

classificação ou uso dominante do modelo de linguagem como *backbone*.

Uma linha adjacente vem da literatura de recuperação em dois estágios, na qual uma busca inicial é refinada por reranqueamento tardio. Em IR geral, ColBERT mostra como preservar interação fina entre consulta e documento com custo viável [27]. No domínio financeiro, Zhao et al. analisam componentes de recuperação em pipelines RAG [28], FinGEAR adota um reranqueador em dois estágios para documentos financeiros longos [29] e Cheng et al. mostram ganho empírico de reranking neural em QA sobre relatórios financeiros [30].

Essas referências indicam que o reranqueamento já foi utilizado no domínio financeiro, mas predominantemente para QA e RAG documental, não para recuperar eventos históricos análogos e suas trajetórias futuras de preço. Trabalhos como *Knowledge-Driven Event Embedding* [31] e *StockMem* [26] aproximam-se mais do uso de memória de eventos em previsão, inclusive com foco em similaridade de eventos e recuperação de cenários análogos. Ainda assim, até onde alcança nossa revisão, não encontramos um antecedente que combine reranqueamento local de candidatos semânticos com seleção de clusters e eventos para reutilizar sequências realizadas de impacto em previsão numérica de curto prazo. Em contraste, o presente artigo propõe uma alternativa mais leve e orientada à previsão numérica: a unidade principal de memória não é um estado latente do modelo, mas uma biblioteca explícita de eventos históricos com sequências observadas de impacto; a recuperação é feita com corte temporal estrito; e a integração com o preditor ocorre por ajuste sequencial e correção residual.

IV. METODOLOGIA

A. Escopo experimental e dados

O escopo empírico do estudo abrange os ativos PETR4, PRIO3 e EXXO34, sincronizados com o Brent (BZ=F) como proxy de commodity. O pipeline trabalha com aproximadamente cinco anos de dados diários provenientes do Yahoo Finance, cobrindo o período que, na base atual de eventos, vai de 10 de novembro de 2020 a 25 de março de 2026. O foco setorial foi deliberado: ativos de óleo e gás são fortemente sensíveis a choques de notícia, commodity, geopolítica e regulação, o que favorece a observação de efeitos recorrentes.

B. Detecção e estruturação de eventos

Eventos são disparados quando a variação percentual diária absoluta do ativo ultrapassa um limiar predefinido. A versão principal do experimento usa um limiar de 2,0%, mas a abordagem também gera análise de sensibilidade para 1,5% e 2,5%. Na configuração de 2,0%, a base atual contém 320 eventos para PETR4, 469 para PRIO3 e 301 para EXXO34.

Quando um evento é detectado, o pipeline consulta um modelo da OpenAI para estruturar um registro JSON contendo data, ativo, retorno do dia, descrição do contexto, motivos identificados, sentimento e fontes. Quando o LLM não encontra contexto suficiente, o pipeline utiliza Tavily como *fallback* de busca e reexecuta a estruturação do evento sobre o material

Algorithm 1 Resumo do pipeline híbrido proposto

- 1: Detectar dias de evento por limiar de retorno absoluto
 - 2: Estruturar cada evento em JSON com contexto textual e motivos
 - 3: Construir a biblioteca histórica com pares *motivo-sequência* e datas
 - 4: Gerar previsões base com LSTM, Autoencoder recorrente e Transformer
 - 5: **for** cada data t na avaliação *walk-forward* **do**
 - 6: Recuperar candidatos anteriores a t , formar um pool semântico curto e aplicar reranqueamento local
 - 7: Agregar as sequências recuperadas por média ponderada pela similaridade semântica original
 - 8: Ajustar a previsão base no horizonte D0–D4
 - 9: Estimar a correção residual usando apenas a janela passada observada
 - 10: Registrar previsões, eventos recuperados e metadados de auditoria
-

recuperado. O conjunto experimental armazena atualmente 1.619 arquivos JSON de evento, com 3.253 motivos textuais identificados.

C. Sequências realizadas e biblioteca de eventos

Cada evento recebe uma sequência realizada de impacto após sua ocorrência. Esse procedimento transforma a coleção de notícias estruturadas em um repositório reutilizável de eventos com trajetórias observadas de preço. O processo calcula retornos do dia do evento e dos pregões seguintes, armazenando sequências D0–D5 quando houver dados suficientes. Se um novo evento ocorre antes do fim da janela, a propagação é interrompida, evitando sobreposição ingênua de impactos. Ao considerar apenas registros com sequência não vazia, a biblioteca corrente de recuperação passa a conter 3.139 pares *motivo-sequência*.

Formalmente, definimos a biblioteca histórica como

$$\mathcal{L} = \{(m_i, q_i, d_i, a_i)\}_{i=1}^N,$$

em que m_i é o motivo textual do evento, q_i é a sequência observada de impacto, d_i é a data do evento e a_i é o ativo associado. Na inferência, apenas itens com $d_i < t$ e ativo compatível com a previsão corrente podem ser usados, o que reduz vazamento de informação futura.

D. Clusters semânticos como camada exploratória

Paralelamente à biblioteca direta de eventos, a abordagem constrói uma camada de clusterização semântica. Os motivos são embedados, podem ser ampliados por variações textuais quando há poucos exemplos e são agrupados por *Agglomerative Clustering*. Na base atual, essa etapa gera 200 clusters exploratórios, 50 para cada um dos quatro grupos (PETR4, PRIO3, EXXO34 e Brent). Esses clusters são úteis para auditoria qualitativa, para a pergunta de pesquisa sobre recorrência de padrões e para o MVP online. Na avaliação offline principal, entretanto, a unidade de recuperação é o evento histórico individual, e não o cluster agregado.

Para a associação entre motivos correntes e clusters históricos, adotou-se uma estratégia de reranqueamento conservador em duas etapas. Primeiro, os candidatos são obtidos por

similaridade semântica via embeddings. Em seguida, apenas um pequeno pool dos melhores candidatos é reranqueado com uma combinação ponderada de similaridade semântica, similaridade lexical e recência temporal. Esse desenho preserva a dominância do sinal semântico e usa o componente lexical apenas como critério de desempate local, reduzindo o risco de aproximações espúrias por sobreposição superficial de termos.

E. Modelos base e ajuste híbrido

Três modelos quantitativos foram treinados como baselines: LSTM, Autoencoder recorrente e Transformer. Todos recebem como entrada séries sincronizadas do ativo alvo e do Brent e produzem previsões base de preço. Sobre essa previsão, o método híbrido adiciona duas camadas.

No treinamento dos modelos base, os checkpoints são gerados separadamente para cada combinação ativo-arquitetura e avaliados diretamente na comparação offline. O artigo não realiza seleção *ex post* entre vários checkpoints de uma mesma arquitetura: cada configuração produz um único checkpoint final salvo ao término do treino. As configurações principais são *seq_len* igual a 15 para todas as arquiteturas, 140 épocas para LSTM e Autoencoder, 160 épocas para Transformer, taxa de aprendizado de 10^{-3} para LSTM e Autoencoder, taxa de 10^{-4} para Transformer e, no caso do Autoencoder, peso de reconstrução igual a 0,5.

A primeira camada é o ajuste por sequência recuperada. Dado o conjunto de motivos correntes M_t , calculamos a similaridade cosseno entre seus embeddings e todos os motivos da biblioteca histórica filtrada. Esse passo define um pool curto de candidatos acima do limiar $\tau = 0,70$. Sobre esse pool, aplicamos um reranqueamento conservador que combina similaridade semântica, sinal lexical local e recência temporal. Os pesos são calibrados por arquitetura, mas mantêm predominância semântica: 0.90/0.07/0.03 para LSTM, 0.91/0.06/0.03 para Autoencoder e 0.84/0.12/0.04 para Transformer. Fora desse pool, nenhum candidato pode subir no ranking, de modo que o reranqueamento funciona apenas como desempate local. Após essa filtragem, mantemos os top- k eventos e calculamos a sequência média ponderada

$$\bar{q}_h = \frac{\sum_{i \in N_t} s_i q_{i,h}}{\sum_{i \in N_t} s_i},$$

em que s_i é a similaridade semântica original do item i e N_t representa o conjunto de eventos recuperados. A previsão base $\hat{y}_{t+h}^{base}$ é ajustada por

$$\hat{y}_{t+h}^{seq} = \hat{y}_{t+h}^{base} \left(1 + \alpha \cdot \bar{s} \cdot \frac{\bar{q}_h}{100} \right),$$

em que $\bar{s}$ é a similaridade média dos eventos selecionados e α é um fator de escala escolhido por busca em grade no conjunto $\{0.1, 0.2, 0.3, 0.4, 0.5, 0.6\}$. Na avaliação offline atual, a recuperação usa top- $k = 5$, limiar de similaridade $\tau = 0,70$ e aplica o ajuste sequencial no horizonte D0–D4, ainda que a biblioteca armazene sequências até D5.

A segunda camada é uma correção residual em regime *walk-forward*. Definimos o residual

$$r_t = y_t - \hat{y}_t^{seq},$$

e treinamos iterativamente um modelo Ridge com atributos derivados apenas do passado observado:

$$x_t = [r_{t-1}, r_{t-2}, sim_t, event_t, hist_t],$$

em que sim_t representa a similaridade média do evento corrente, $event_t$ é um indicador binário de evento e $hist_t$ é a quantidade de eventos históricos usados na recuperação. A previsão final é então dada por

$$\hat{y}_t^{hyb} = \hat{y}_t^{seq} + g(x_t),$$

com $g(\cdot)$ estimado apenas a partir da janela passada. Na implementação atual, o ajuste residual usa janela de 15 observações. Essa formulação não deve ser interpretada como identificação causal formal; ela representa um mecanismo de ajuste informado por eventos históricos comparáveis sob restrição temporal estrita.

V. AVALIAÇÃO EXPERIMENTAL

A. Protocolo experimental

A avaliação foi realizada de forma offline, em regime *walk-forward*, sobre os três ativos e as três arquiteturas base. Para cada combinação ativo-modelo, o pipeline gera quatro trilhas: previsão base, ajuste apenas por sequência recuperada (*SeqOnly*), correção apenas residual (*ResidualOnly*) e previsão híbrida completa. Ao todo, o experimento atual produz 12.159 previsões fora da amostra, distribuídas uniformemente entre nove configurações.

As métricas principais são RMSE e MAE, por refletirem erro de magnitude em escala original, que é o alvo central deste estudo de regressão. O RMSE recebe maior destaque por penalizar mais fortemente erros grandes em dias de choque, enquanto o MAE complementa a leitura com uma medida mais direta e menos sensível a outliers. Como métricas complementares, também reportamos *directional accuracy*, percentual de dias em que o híbrido supera o baseline, e análises de robustez por ano. A *directional accuracy* é mantida como medida auxiliar porque informa acerto de sinal, mas não captura a magnitude do erro. Além disso, o pipeline gera logs de decisão por ativo e arquitetura, registrando motivos, similaridade média, quantidade de eventos históricos utilizados e datas de referência recuperadas. Esses artefatos reforçam a auditabilidade da camada informacional.

Do ponto de vista metodológico, três cuidados são centrais no protocolo. Primeiro, a recuperação histórica usa apenas eventos anteriores à data prevista, o que reduz vazamento de informação futura. Segundo, o ajuste residual é estimado em regime *walk-forward*, com atributos calculados apenas a partir do passado observado. Terceiro, a avaliação inclui uma ablação explícita para separar o efeito do ajuste sequencial por similaridade do efeito da correção residual.

Com esse desenho, a avaliação permite discutir de forma integrada não apenas a redução agregada de erro frente aos baselines quantitativos, mas também o comportamento do método em dias com e sem evento, a recorrência de sequências semanticamente comparáveis, a robustez entre ativos, arquiteturas e recortes anuais, e os limites da abordagem em cenários

TABLE I
RMSE DOS MODELOS BASE E HÍBRIDOS POR ATIVO E ARQUITETURA

Ativo	Modelo	RMSE Base	RMSE Híbrido	Ganho
PETR4	LSTM	0.9632	0.4650	0.4982
PRI03	LSTM	1.5592	0.8530	0.7062
EXXO34	LSTM	2.0610	1.1624	0.8985
PETR4	Autoencoder	1.0216	0.4678	0.5539
PRI03	Autoencoder	1.6077	0.8578	0.7499
EXXO34	Autoencoder	2.1269	1.1744	0.9525
PETR4	Transformer	1.0858	0.4752	0.6106
PRI03	Transformer	1.3836	0.8394	0.5442
EXXO34	Transformer	2.8142	1.3883	1.4259

TABLE II
ABLAÇÃO AGREGADA POR MÉDIA DE RMSE

Configuração	RMSE médio
Modelo base	1.6248
SeqOnly	1.5768
ResidualOnly	0.8881
Híbrido completo	0.8537

de histórico pouco comparável ou sob diferentes limiares de detecção. Assim, os resultados a seguir são interpretados menos como respostas isoladas a perguntas independentes e mais como evidências complementares sobre desempenho, estabilidade, auditabilidade e sensibilidade do método proposto.

B. Resultados principais

A Tabela I resume os resultados de RMSE por ativo e arquitetura. O ganho do método híbrido aparece em todos os nove cenários avaliados. Na configuração atual, que incorpora um reranqueamento conservador apenas como desempate dentro de um pool semântico curto, a melhora absoluta varia de 0.4982 a 1.4259 pontos de RMSE, com destaque para EXXO34 com Transformer.

Em média, o RMSE cai de 1.6248 para 0.8537, o que corresponde a uma redução agregada de 47,5%. O MAE médio cai de 1.2445 para 0.6253, uma redução de 49,8%. Além disso, o método híbrido supera o modelo base em 76,2% dos dias avaliados. Em termos práticos, isso significa que o ganho não fica restrito a um único ativo nem a uma única arquitetura. Ele aparece de forma consistente em LSTM, Autoencoder e Transformer, bem como em empresas mais maduras e mais novas dentro do recorte analisado.

C. Ablação e interpretação do ganho

A Tabela II mostra que a camada *SeqOnly*, isoladamente, gera melhora modesta, enquanto a maior parte do ganho vem da combinação entre recuperação semântica e correção residual *walk-forward*. Isso indica que o valor do método não está apenas em identificar eventos similares, mas em usar essa informação como insumo para uma adaptação residual sensível ao contexto informacional.

Os números da ablação mostram três mensagens importantes. Primeiro, há algum valor na recuperação semântica pura, mas ela sozinha reduz pouco o erro médio (3,0%).

Segundo, a correção residual orientada por informação de evento é o principal motor de ganho, reduzindo o RMSE médio em 45,3% frente ao baseline. Terceiro, a combinação das duas etapas ainda acrescenta melhora adicional, levando o ganho agregado a 47,5%.

D. Resultados por regime e robustez temporal

Ao separar as observações em dias marcados pela biblioteca de eventos e dias sem marcação, o híbrido melhora em ambos os casos. Em termos médios de MAE, a redução é de 48,1% nos dias com evento e de 53,4% nos dias sem evento. Esse resultado sugere que a camada residual aprende regularidades úteis mesmo fora dos dias explicitamente marcados. Ainda assim, o método continua dependente de uma base semântica coerente para capturar os choques mais informacionais.

As análises auxiliares também indicam robustez temporal relevante: 60 de 63 subgrupos ano-ativo-modelo melhoram em relação ao baseline. As três exceções aparecem em janelas iniciais de 2020 com apenas três observações. Esse comportamento deve ser interpretado à luz da heterogeneidade da amostra. O recorte inclui empresas mais maduras e séries mais longas, como Petrobras, e empresas relativamente mais novas no mercado observado, o que reduz a quantidade de observações disponíveis em janelas muito antigas para alguns ativos. Por isso, os poucos casos sem ganho concentram-se em faixas temporais muito curtas e não indicam degradação sistemática do método.

E. Discussão

Em conjunto, os resultados sugerem que a biblioteca de eventos recuperados funciona como um mecanismo de memória externa útil para previsão numérica. Seu valor prático, contudo, depende de duas condições: uma base histórica minimamente rica e um procedimento de recuperação sob restrição temporal. Isso ajuda a explicar por que a combinação entre recuperação e residual supera tanto o baseline puro quanto o ajuste semântico isolado. O método também preserva uma propriedade importante para uso acadêmico: cada ajuste pode ser rastreado a eventos históricos concretos, o que facilita análise qualitativa, inspeção de falhas e discussão econômica dos resultados.

Como complemento interpretativo, a Tabela III resume os cinco assuntos com maior alteração absoluta de preço no horizonte futuro entre os clusters com pelo menos cinco eventos. Diferentemente do ajuste preditivo principal, que opera no horizonte D0–D4, essa tabela usa D1–D5 para enfatizar a propagação posterior ao dia do evento e evitar que o choque inicial domine sozinho a interpretação. O critério usado foi a soma absoluta da trajetória média posterior nesse horizonte, preservando o sinal médio observado. Assim, a tabela não mede a polaridade semântica intrínseca do assunto, mas sim o comportamento médio dos preços após eventos daquele tipo.

VI. AMEAÇAS À VALIDADE

A. Validade interna

A principal ameaça à validade interna decorre da dependência de serviços externos para estruturação de notícias

TABLE III
ASSUNTOS COM MAIOR ALTERAÇÃO ABSOLUTA DE PREÇO NO HORIZONTE FUTURO

Assunto representativo	Ativo	<i>n</i>	Impacto D1–D5
Preocupações fiscais e políticas no Brasil sobre o ativo	PETR4	9	+6.2527
Redução dos riscos geopolíticos no Oriente Médio	BRENT	8	-5.3361
Tensões geopolíticas entre Rússia e Ucrânia	BRENT	14	-5.1211
Sanções e restrições ao petróleo russo	BRENT	12	-4.3527
Intervenção estatal e política na gestão da empresa	PETR4	7	-4.0636

e geração de embeddings. Mesmo com prompts controlados, JSON estruturado e *fallback* de busca, ainda existe variação induzida pelo modelo de linguagem e pela disponibilidade de conteúdo recuperado. Além disso, a abordagem não busca demonstrar causalidade econômica formal. O que o método mostra é que certos eventos comparáveis carregam informação útil para ajuste preditivo sob restrição temporal.

B. Validade de construto

O construto “evento relevante” depende de uma heurística baseada em limiar de retorno diário. Embora a abordagem inclua análise de sensibilidade para 1,5%, 2,0% e 2,5%, ainda há risco de que alguns movimentos importantes fiquem fora da base ou de que certos dias entrem como eventos sem corresponder a um choque informacional claro. De forma semelhante, os clusters semânticos devem ser entendidos como apoio exploratório e não como validação definitiva de categorias econômicas.

C. Validade externa

O escopo empírico está restrito ao setor de óleo e gás e a três ativos específicos, todos sincronizados com o Brent. Esse desenho foi escolhido por favorecer interpretação econômica e recorrência de choques informacionais, mas limita a generalização imediata para outros setores, mercados ou frequências temporais. A extensão da abordagem para bancos, varejo, tecnologia ou dados intradiários ainda precisa ser demonstrada empiricamente.

D. Validade estatística e de reprodução

Embora o número total de previsões fora da amostra seja expressivo, alguns recortes anuais iniciais possuem poucas observações por causa da maturidade diferente entre os ativos analisados. Empresas mais maduras oferecem janelas históricas mais densas, enquanto ativos relativamente mais novos no recorte observado geram menos pontos em anos iniciais. Essa assimetria afeta sobretudo os recortes temporais mais curtos, justamente onde se concentram os poucos casos sem ganho. Além disso, os artefatos experimentais já incluem logs, tabelas auxiliares e testes de reprodutibilidade, mas ainda não contemplam uma bateria estatística mais ampla, como testes formais de significância, intervalos de confiança por janela ou validação cruzada temporal em múltiplos cortes.

VII. CONCLUSÃO

Este trabalho apresentou um método de previsão híbrida para séries temporais financeiras no qual notícias são convertidas em eventos estruturados e reutilizadas por meio de recuperação semântica de episódios históricos comparáveis. A contribuição central do artigo está em combinar uma biblioteca histórica de eventos com corte temporal estrito, um ajuste sequencial ponderado por similaridade e uma correção residual *walk-forward* sobre baselines quantitativos padrão.

As evidências quantitativas mostram que essa combinação melhora de forma consistente os três baselines avaliados. O RMSE médio cai 47,5%, o MAE médio cai 49,8% e o método supera o baseline em mais de três quartos dos dias avaliados. A ablação reforça que o ganho não vem de um único componente isolado, mas da interação entre recuperação semântica e adaptação residual. Em paralelo, a análise exploratória dos clusters indica quais assuntos aparecem associados a trajetórias médias posteriores de maior magnitude, preservando uma camada adicional de auditabilidade.

Como próximos passos, destacam-se quatro direções. A primeira é reconstruir a base semântica por janelas temporais para reduzir ainda mais o risco de contaminação histórica. A segunda é ampliar a avaliação para outros setores e mercados. A terceira é incorporar testes estatísticos mais fortes sobre os ganhos observados. A quarta é congelar artefatos não deterministas para reprodução integral do experimento.

ACKNOWLEDGMENT

The authors thank CNPq, CAPES, and FAPERJ for partially sponsoring this research.

REFERENCES

- [1] P. C. Tetlock, "Giving content to investor sentiment: The role of media in the stock market," *Journal of Finance*, vol. 62, no. 3, pp. 1139–1168, 2007.
- [2] P. C. Tetlock, M. Saar-Tsechansky, and S. Macskassy, "More than words: Quantifying language to measure firms' fundamentals," *Journal of Finance*, vol. 63, no. 3, pp. 1437–1467, 2008.
- [3] Y. Xu and S. B. Cohen, "Stock movement prediction from tweets and historical prices," in *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics*, 2018, pp. 1970–1979.
- [4] R. Sawhney, S. Agarwal, A. Wadhwa, and R. R. Shah, "Deep attentive learning for stock movement prediction from social media text and company correlations," in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2020, pp. 8415–8426.
- [5] T. Fischer and C. Krauss, "Deep learning with long short-term memory networks for financial market predictions," *European Journal of Operational Research*, vol. 270, no. 2, pp. 654–669, 2018.
- [6] W. Bao, J. Yue, and Y. Rao, "Adeeplearning framework for financial time series using stacked autoencoders and long short term memory," *PLOS ONE*, vol. 12, no. 7, p. e0180944, 2017.
- [7] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 5998–6008.
- [8] B. Lim, S. O. Arık, N. Loeff, and T. Pfister, "Temporal fusion transformers for interpretable multi-horizon time series forecasting," *International Journal of Forecasting*, vol. 37, no. 4, pp. 1748–1764, 2021.
- [9] H. Wu, J. Xu, J. Wang, and M. Long, "Informer: Beyond efficient transformer for long sequence time-series forecasting," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, 2021, pp. 11 106–11 115.
- [10] T. Loughran and B. McDonald, "When is a liability not a liability? textual analysis, dictionaries, and 10-ks," *Journal of Finance*, vol. 66, no. 1, pp. 35–65, 2011.
- [11] G. Mitra and L. Mitra, "The impact of news sentiment on stock returns," *Quantitative Finance*, vol. 11, no. 7, pp. 1037–1061, 2011.
- [12] T. Mikolov, K. Chen, G. Corrado, and J. Dean, "Efficient estimation of word representations in vector space," in *Proceedings of the International Conference on Learning Representations*, 2013.
- [13] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "Bert: Pre-training of deep bidirectional transformers for language understanding," *Proceedings of the North American Chapter of the Association for Computational Linguistics*, vol. 1, pp. 4171–4186, 2019.
- [14] D. Araci, "Finbert: Financial sentiment analysis with pre-trained language models," *IEEE Access*, vol. 7, pp. 155 448–155 458, 2019.
- [15] N. Reimers and I. Gurevych, "Sentence-bert: Sentence embeddings using siamese bert-networks," *Proceedings of the Conference on Empirical Methods in Natural Language Processing*, pp. 3982–3992, 2019.
- [16] E. F. Fama, "Efficient capital markets: A review of theory and empirical work," *Journal of Finance*, vol. 25, no. 2, pp. 383–417, 1970.
- [17] D. M. Cutler, J. M. Poterba, and L. H. Summers, "What moves stock prices?" *Journal of Portfolio Management*, vol. 15, no. 3, pp. 4–12, 1989.
- [18] N. Barberis, A. Shleifer, and R. Vishny, "A model of investor sentiment," *Journal of Finance*, vol. 53, no. 1, pp. 307–343, 1998.
- [19] H. Hong and J. C. Stein, "A unified theory of underreaction, momentum trading, and overreaction in asset markets," *Journal of Finance*, vol. 54, no. 6, pp. 2143–2184, 1999.
- [20] X. Ding, Y. Zhang, T. Liu, and J. Duan, "Using structured events to predict stock price movement: An empirical investigation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1415–1425.
- [21] —, "Deep learning for event-driven stock prediction," in *Proceedings of the Twenty-Fourth International Joint Conference on Artificial Intelligence (IJCAI)*, 2015, pp. 2327–2333.
- [22] B. Banushev, "stockpredictionai: Using the latest advancements in ai to predict stock market movements," <https://github.com/borisbanushev/stockpredictionai>, 2019, gitHub repository. Accessed: 2026-03-27.
- [23] D. Luo, W. Liao, Z. Lin, and D. Song, "Causality-guided multi-memory interaction network for multivariate stock price movement prediction," in *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*, 2023.
- [24] Z. Li, "Retrieval-augmented forecasting with tabular time series data," in *Proceedings of the 4th Table Representation Learning Workshop*, 2025, pp. 192–199.
- [25] M. Xiao, Z. Jiang, L. Qian, Z. Chen, Y. He, Y. Xu, Y. Jiang, D. Li, R.-L. Weng, M. Peng, J. Huang, S. Ananiadou, and Q. Xie, "Retrieval-augmented large language models for financial time series forecasting," *arXiv preprint arXiv:2502.05878*, 2025.
- [26] H. Wang, W. Xiao, S. Han, and H. Huang, "Stockmem: An event-reflection memory framework for stock forecasting,"

arXiv preprint arXiv:2512.02720, 2025.

- [27] O. Khattab and M. Zaharia, “Colbert: Efficient and effective passage search via contextualized late interaction over bert,” in *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2020, pp. 39–48.
- [28] Y. Zhao, P. Singh, H. Bhathena, B. Ramos, A. Joshi, S. Gadiyaram, and S. Sharma, “Optimizing llm based retrieval augmented generation pipelines in the financial domain,” in *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 6: Industry Track)*, 2024, pp. 279–294.
- [29] Y. Li, M. Wang, M. de Carvalho, S. Sabanis, and T. Ma, “Fingear: Financial mapping-guided enhanced answer retrieval,” in *Findings of the Association for Computational Linguistics: EMNLP 2025*, 2025, pp. 7239–7255.
- [30] Z. Cheng, L. Lai, Y. Liu, K. Cheng, and X. Qi, “Enhancing financial report question-answering: A retrieval-augmented generation system with reranking analysis,” *arXiv preprint arXiv:2603.16877*, 2026.
- [31] X. Ding, Y. Zhang, T. Liu, and J. Duan, “Knowledge-driven event embedding for stock prediction,” in *Proceedings of COLING 2016, the 26th International Conference on Computational Linguistics: Technical Papers*, 2016, pp. 2133–2142.